WNIOSKOWANIE W WARUNKACH NIEPEWNOŚCI

PROJEKT

Analiza wpływu wybranych czynników na udar Jakub Witkowski

1. Zbiór danych

Dane zostały pobrane ze strony https://www.kaggle.com. Zawierają informacje o pacjentach z ryzykiem udaru. Dane zawierają 11 kolumn: płeć, wiek, nadciśnienie, choroby serca, stan cywilny, rodzaj pracy, rodzaj zamieszkania, poziom glukozy, bmi, palący lub nie palący oraz czy pacjent miał już wcześniej udar.

_	gender ‡	age ‡	hypertension ‡	heart_disease ‡	ever_married ‡	work_type ‡	Residence_type ‡	avg_glucose_level ‡	bmi ‡	smoking_status ‡	stroke ‡
1	Male	67.00			Yes	Private	Urban	228.69	36.6	formerly smoked	1
2	Female	61.00			Yes	Self-employed	Rural	202.21	N/A	never smoked	1
3	Male	80.00			Yes	Private	Rural	105.92	32.5	never smoked	1
4	Female	49.00			Yes	Private	Urban	171.23	34.4	smokes	1
5	Female	79.00			Yes	Self-employed	Rural	174.12		never smoked	1
6	Male	81.00			Yes	Private	Urban	186.21		formerly smoked	1
7	Male	74.00			Yes	Private	Rural	70.09	27.4	never smoked	1
8	Female	69.00				Private	Urban	94.39	22.8	never smoked	1
9	Female	59.00			Yes	Private	Rural	76.15		Unkno wn	1
10	Female	78.00			Yes	Private	Urban	58.57	24.2	Unkno wn	1
11	Female	81.00			Yes	Private	Rural	80.43	29.7	never smoked	1
12	Female	61.00			Yes	Govt_job	Rural	120.46	36.8	smokes	1
13	Female	54.00			Yes	Private	Urban	104.51	27.3	smokes	1
14	Male	78.00			Yes	Private	Urban	219.84		Unkno wn	1
15	Female	79.00			Yes	Private	Urban	214.09	28.2	never smoked	1
16	Female	50.00			Yes	Self-employed	Rural	167.41	30.9	never smoked	1
17	Male	64.00			Yes	Private	Urban	191.61	37.5	smokes	1
18	Male	75.00			Yes	Private	Urban	221.29	25.8	smokes	1
19	Female	60.00				Private	Urban	89.22	37.8	never smoked	1
20	Male	57.00			No	Govt_job	Urban	217.08	N/A	Unkno wn	1
21	Female	71.00			Yes	Govt_job	Rural	193.94	22.4	smokes	1
22	Female	52.00			Yes	Self-employed	Urban	233.29	48.9	never smoked	1
23	Female	79.00			Yes	Self-employed	Urban	228.70	26.6	never smoked	1
24	Male	82.00			Yes	Private	Rural	208.30	32.5	Unkno wn	1

2. Wykonanie projektu

Pierwszym krokiem była obróbka danych. Usunięte zostały niepotrzebne kolumny oraz zostały zmienione nazwy dla pozostałych kolumn.

```
#usuwanie kolumn
dane <- dane[,-c(1,5,8,9,10,12)]
#zmiana nazw kolumn
colnames(dane) <- c("P","w","N","C","RP","S")
```

Następnie został zmieniony typ danych na factor.

```
#zmiana typu na factor
dane$P <- as.factor(dane$P)
dane$W <- as.factor(dane$N)
dane$C <- as.factor(dane$C)
dane$RP <- as.factor(dane$RP)
dane$S <- as.factor(dane$S)</pre>
```

Po obróbce danych zostało 6 kolumn, z których zostały stworzone cechy:

- P płeć
- W wiek
- N nadciśnienie
- C stan cywilny
- RP rodzaj pracy
- S-palacz

•	P ‡	w ÷	N ÷	c ‡	RP ‡	s ‡
1	Male	67	0	Yes	Private	formerly smoked
2	Female	61	0	Yes	Self-employed	never smoked
3	Male	80	0	Yes	Private	never smoked
4	Female	49	0	Yes	Private	smokes
5	Female	79	1	Yes	Self-employed	never smoked
6	Male	81	0	Yes	Private	formerly smoked
7	Male	74	1	Yes	Private	never smoked
8	Female	69	0	No	Private	never smoked
9	Female	59	0	Yes	Private	Unkno wn
10	Female	78	0	Yes	Private	Unkno wn
11	Female	81	1	Yes	Private	never smoked
12	Female	61	0	Yes	Govt_job	smokes
13	Female	54	0	Yes	Private	smokes
14	Male	78	0	Yes	Private	Unkno wn
15	Female	79	0	Yes	Private	never smoked
16	Female	50	1	Yes	Self-employed	never smoked
17	Male	64	0	Yes	Private	smokes
18	Male	75	1	Yes	Private	smokes
19	Female	60	0	No	Private	never smoked
20	Male	57	0	No	Govt_job	Unkno wn
21	Female	71	0	Yes	Govt_job	smokes

W kolejnym kroku utworzyłem ręcznie sieć Bayesa. Wybrane czynniki zostały dopasowane według moich własnych przemyśleń.

```
#tworzenie sieci
dag <- empty.graph(nodes=c('P','W','N','C','RP','S'))

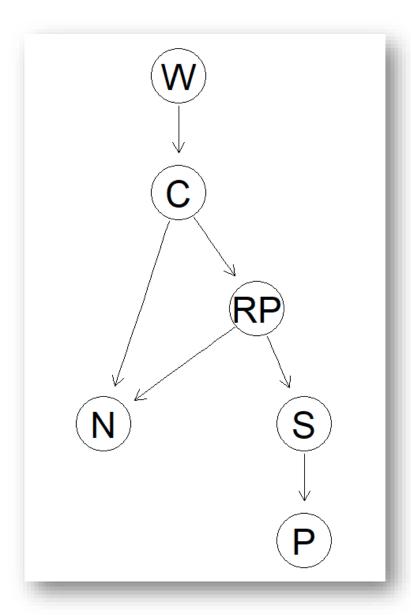
dag <- set.arc(dag, from="W", to="C")
dag <- set.arc(dag, from="C", to="RP")
dag <- set.arc(dag, from="C", to="N")
dag <- set.arc(dag, from="RP", to="N")
dag <- set.arc(dag, from="RP", to="S")
dag <- set.arc(dag, from="S", to="P")

dag
score(dag,data=dane,type="bic")
graphviz.plot(dag)</pre>
```

Zwrócone wyniki:

```
Random/Generated Bayesian network
 model:
   [W][C|W][RP|C][N|C:RP][S|RP][P|S]
                                         6
 nodes:
                                         6
 arcs:
                                         0
   undirected arcs:
   directed arcs:
                                         6
 average markov blanket size:
                                        2.00
 average neighbourhood size:
                                         2.00
 average branching factor:
                                         1.00
 generation algorithm:
                                         Empty
 score(dag,data=dane,type="bic")
[1] -41338.28
```

Graf:



Następnym krokiem jest badanie niezależności zmiennych. Niezależności zostały zbadane za pomocą testu χ^2 :

 H_0 : Zmienne są niezależne

 H_1 : Zmienne są zależne

Wykonane testy:

• Płeć i wiek

p-value < 0.05, więc odrzucamy, mogą być zależne

• Płeć i nadciśnienie

```
> ci.test('P','N',test='x2',data=dane)

Pearson's X^2

data: P ~ N
x2 = 2.4096, df = 2, p-value = 0.2998
alternative hypothesis: true value is greater than 0
```

Nie ma podstaw do odrzucenia, zmienne są niezależne

• Płeć i stan cywilny

• Płeć i rodzaj pracy

p-value < 0.05, więc odrzucamy, mogą być zależne

• Płeć i osoba paląca

p-value < 0.05, więc odrzucamy, mogą być zależne

• Wiek i nadciśnienie

p-value < 0.05, więc odrzucamy, mogą być zależne

• Wiek i stan cywilny

• Wiek i rodzaj pracy

p-value < 0.05, więc odrzucamy, mogą być zależne

• Wiek i osoba paląca

p-value < 0.05, więc odrzucamy, mogą być zależne

• Nadciśnienie i stan cywilny

p-value < 0.05, wiec odrzucamy, mogą być zależne

• Nadciśnienie i rodzaj pracy

• Nadciśnienie i osoba paląca

p-value < 0.05, więc odrzucamy, mogą być zależne

• Stan cywilny i rodzaj pracy

p-value < 0.05, więc odrzucamy, mogą być zależne

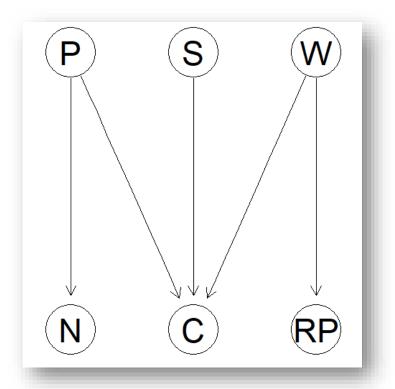
• Stan cywilny i osoba paląca

• Rodzaj pracy i osoba paląca

p-value < 0.05, więc odrzucamy, mogą być zależne

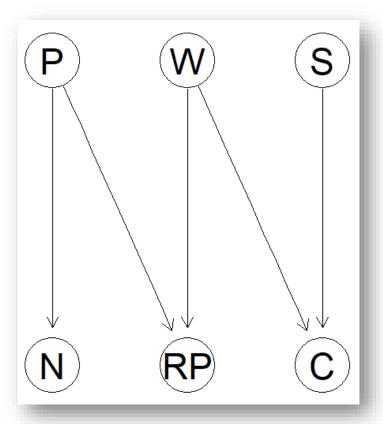
3. Algorytmy

• GS



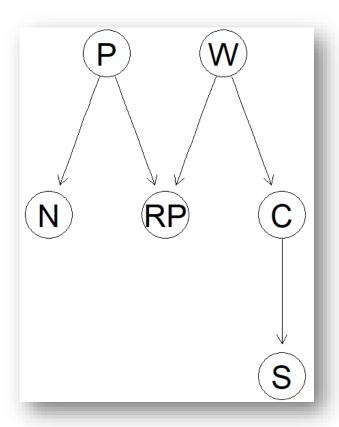
Score: -47120.47

• Pc.stable



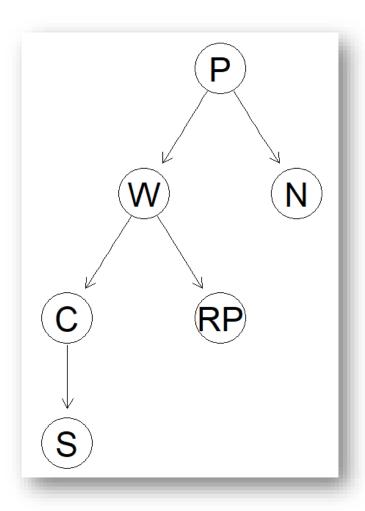
Score: -47159.4

MMPC



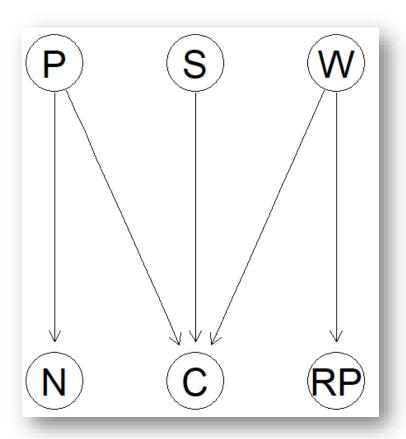
Score: -45637.45

HPC



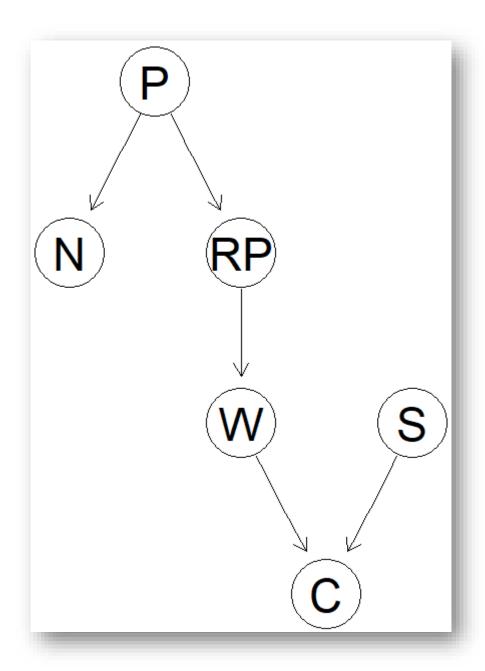
Score: -42963.51

• Si.hiton



Score: -47120.47

HC



Score: -43708.22

Tabela wyników dla przedstawionych algorytmów:

Algorytm	Wynik
GS	-47120.47
Pc.stable Pc.stable	-47159.4
MMPC	-45637.45
HPC	-42963.51
Si.hiton	-47120.47
HC	-43708.22
Ręcznie	-41338.28

Jak można zauważyć siecią z najlepszym wynikiem okazała się ta zrobiona ręcznie.

4. Prawdopodobieństwa dla najlepszego wyniku

```
siec<- bn.fit(dag, dane)
siec
```

```
Bayesian network parameters
 Parameters of node P (multinomial distribution)
Conditional probability table:
        formerly smoked never smoked
                                        smokes
           Female
 other
 Parameters of node W (multinomial distribution)
Conditional probability table:
        0.08 0.16
                                0.24
                                           0.32
0.0003913894 0.0005870841 0.0009784736 0.0009784736 0.0003913894 0.0005870841 0.0009784736
              0.72 0.8
                                           0.88
                                                                    1.08
0.0007827789 0.0009784736 0.0007827789 0.0009784736 0.0009784736 0.0015655577 0.0007827789
       1.24
                  1.32 1.4 1.48 1.56
                                                             1.64
0.0015655577 0.0015655577 0.0005870841 0.0011741683 0.0007827789 0.0015655577 0.0011741683
        1.8
                  1.88
                                                                                   6
0.0017612524 \ \ 0.0015655577 \ \ 0.0107632094 \ \ 0.0090019569 \ \ 0.0066536204 \ \ 0.0127201566 \ \ 0.0046966732
                                            10
0.0062622309 0.0113502935 0.0074363992 0.0068493151 0.0070450098 0.0088062622 0.0111545988
        14
                    15
                                 16
                                                          18
                                                                      19
0.0105675147 0.0088062622 0.0101761252 0.0117416830 0.0117416830 0.0097847358 0.0115459883
         21
                                                                     26
0.0091976517 0.0088062622 0.0125244618 0.0107632094 0.0111545988 0.0121330724 0.0107632094
                     29
                                 30
                                             31
         28
0.0105675147 0.0099804305 0.0107632094 0.0154598826 0.0138943249 0.0111545988 0.0133072407
                                             38
0.0105675147 0.0101761252 0.0148727984 0.0140900196 0.0138943249 0.0144814090 0.0142857143
0.0138943249 0.0136986301 0.0146771037 0.0166340509 0.0121330724 0.0146771037 0.0129158513
                    50
0.0154598826 0.0162426614 0.0168297456 0.0176125245 0.0166340509 0.0170254403 0.0162426614
                                 58
                                                          60
                                                                      61
0.0150684932 0.0185909980 0.0133072407 0.0156555773 0.0140900196 0.0148727984 0.0144814090
                                            66
0.0144814090 0.0103718200 0.0121330724 0.0117416830 0.0095890411 0.0091976517 0.0105675147
0.0088062622 0.0119373777 0.0088062622 0.0090019569 0.0078277886 0.0103718200 0.0097847358
                                             80
0.0082191781 0.0199608611 0.0166340509 0.0136986301 0.0117416830 0.0109589041
```

```
Parameters of node N (multinomial distribution)
Conditional probability table:
, , RP = children
     No Yes
 0 1.00000000
 1 0.00000000
, , RP = Govt_job
                  Yes
0 0.92307692 0.88148148
 1 0.07692308 0.11851852
, , RP = Never_worked
 C No Yes
 0 1.00000000
 1 0.00000000
, , RP = Private
                   Yes
 0 0.95736906 0.88307985
 1 0.04263094 0.11692015
, , RP = Self-employed
0 0.91818182 0.80959097
 1 0.08181818 0.19040903
```

```
Parameters of node C (multinomial distribution)
Conditional probability table:
             0.16
                    0.24
                           0.32
                                  0.4
                                        0.48
 0.8
                    0.88
                                  1.08
 14
 No 0.96000000 0.93220339 0.87234043 0.84444444 0.89062500 0.65454545 0.57894737 0.61290323
 Yes 0.04000000 0.06779661 0.12765957 0.15555556 0.10937500 0.34545455 0.42105263 0.38709677
 No 0.58181818 0.48148148 0.50980392 0.36363636 0.34177215 0.33802817 0.19298246 0.27941176
 Yes 0.41818182 0.51851852 0.49019608 0.63636364 0.65822785 0.66197183 0.80701754 0.72058824
 No 0.16666667 0.23076923 0.18421053 0.12500000 0.12676056 0.21621622 0.16438356 0.14084507
 Yes 0.8333333 0.76923077 0.81578947 0.87500000 0.87323944 0.78378378 0.83561644 0.85915493
 No 0.10000000 0.14666667 0.09411765 0.09677419 0.05333333 0.10606061 0.06329114 0.10843373
 Yes 0.90000000 0.85333333 0.90588235 0.90322581 0.94666667 0.89393939 0.93670886 0.89156627
                            54
 No 0.10465116 0.07777778 0.04705882 0.04597701 0.08433735 0.07792208 0.08421053 0.11764706
 Yes 0.89534884 0.92222222 0.95294118 0.95402299 0.91566265 0.92207792 0.91578947 0.88235294
              60
                     61
                            62
                                         64
 NO 0.03750000 0.09722222 0.03947368 0.05405405 0.02702703 0.05660377 0.06451613 0.06666667
 Yes 0.96250000 0.90277778 0.96052632 0.94594595 0.97297297 0.94339623 0.93548387 0.93333333
 67 68 69 70 71 72 73 74 No 0.00000000 0.08510638 0.16666667 0.02222222 0.04918033 0.02222222 0.10869565 0.05000000
 Yes 1.00000000 0.91489362 0.83333333 0.97777778 0.95081967 0.97777778 0.89130435 0.95000000
```

```
C 75 76 77 78 79 80 81 82
No 0.05660377 0.04000000 0.02380952 0.12745098 0.15294118 0.10000000 0.13333333 0.14285714
Yes 0.94339623 0.96000000 0.97619048 0.87254902 0.84705882 0.90000000 0.86666667 0.85714286
Parameters of node RP (multinomial distribution)

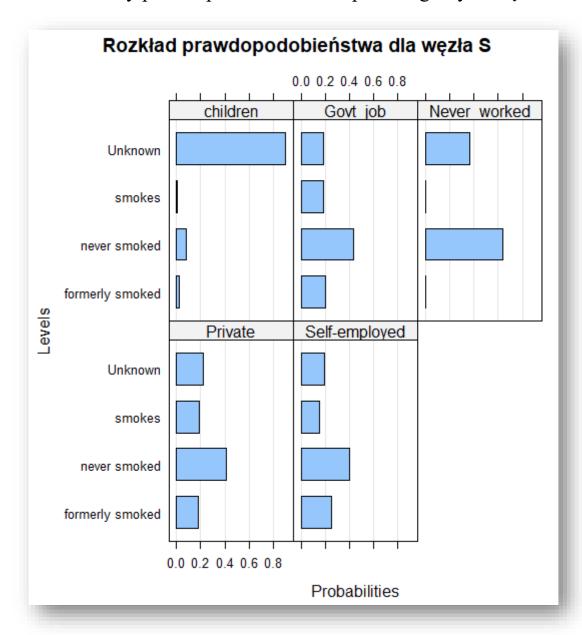
Conditional probability table:

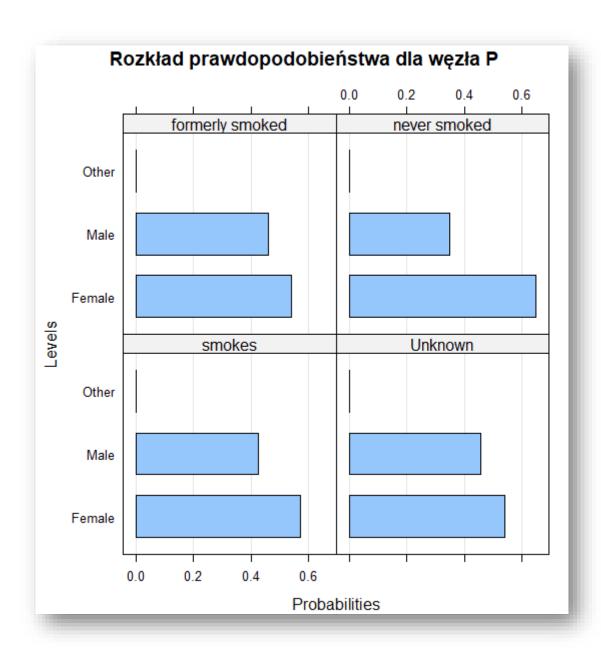
C
RP No Yes
Children 0.39100740 0.00000000
Govt_job 0.06659078 0.16104981
Never_worked 0.01252134 0.00000000
Private 0.46727376 0.62749776
Self-employed 0.06260672 0.21145243
Parameters of node S (multinomial distribution)

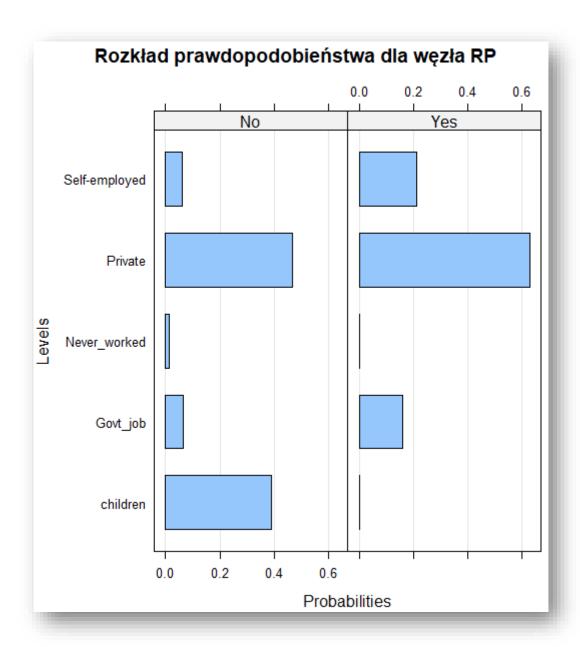
Conditional probability table:

RP
S Children Govt_job Never_worked Private Self-employed
formerly smoked 0.018922853 0.202435312 0.000000000 0.181538462 0.253968254
never smoked 0.078602620 0.429223744 0.636363636 0.414017094 0.404151404
smokes 0.002911208 0.182648402 0.000000000 0.185641026 0.151404151
Unknown 0.899563319 0.185692542 0.363636364 0.218803419 0.190476190
```

5. Rozkłady prawdopodobieństw dla poszczególnych węzłów







6. Prawdopodobieństwa warunkowe

 Prawdopodobieństwo udaru dla osoby mającej nadciśnienie będąc w przedziale wiekowym 75-84.

```
W 0-18 19-24 25-34 35-44 0.0001265663 0.0005062650 0.0018352107 0.0072142767 45-54 55-64 65-74 75-84 0.0213896975 0.0740412606 0.2776230857 0.3259081129 85-94 95+ 0.2684470320 0.0229084926
```

Prawdopodobieństwo obliczone za pomocą wzoru Bayesa:

$$P(N = 1|W = 75 - 84) = \frac{P(W = 75 - 84|N = 1) * P(N = 1)}{P(W = 75 - 84)}$$

 Prawdopodobieństwo udaru dla kobiet, które są samozatrudnione, palące i będące kiedykolwiek zamężne

```
querygrain(junction, nodes = c("P","RP", "C", "S"), type="joint")
```

```
, , RP = Self-employed, C = Yes

S
P formerly smoked never smoked smokes Unknown
Female 1.899240e-02 0.03642505 0.012034403 0.01430952
Male 1.620526e-02 0.01964997 0.008972553 0.01211859
Other 3.981635e-05 0.00000000 0.000000000 0.00000000
```

Prawdopodobieństwo obliczone za pomocą wzoru Bayesa:

```
P(S = Smokes \land RP = Self - employed \land P = Female \land C = Yes)
= P(P = Female) * P(C = Yes|P = Female)
* P(C = Yes|P = Female) * P(RP = Self - employed|P = Female)
* P(S = Smokes|RP = Self - employed)
```

 Prawdopodobieństwo udaru dla mężczyzn z przedziału wiekowego 45-54, którzy byli kiedykolwiek żonaci

```
C
NO Yes
0.3525138 0.6474862
```

 Prawdopodobieństwo udaru dla mężczyzn, którzy palą, pracują w sektorze prywatnym, nie mają nadciśnienia, byli/są żonaci i mają 71 lat

```
#p4
options(max.print = 22300)
querygrain(junction, nodes = c("W","C","N", "RP", "S","P"), type="joint")
```

```
s
P formerly smoked never smoked smokes
Female 6.154078e-04 0.0016914855 0.0006688899
Male 5.250964e-04 0.0009124938 0.0004987077
Other 1.290163e-06 0.0000000000 0.000000000
```

```
P(P = Male \land S = Smokes \land RP = Private \land N = 0 \land C = Yes \land W = 71)
= P(W = 71) * P(C = Yes|W = 71) * P(N = 0|C = Yes)
* P(RP = Private|C = Yes) * P(S = Smokes|RP = Private)
* P(P = Male|S = Smokes)
```

7. Podsumowanie

Projekt miał na celu wykorzystanie sieci Bayesa do analizy danych dotyczących udaru mózgu. Poprzez konstrukcję struktury sieci, dopasowanie jej do danych i obliczanie prawdopodobieństw warunkowych, mogliśmy uzyskać wgląd w zależności między różnymi zmiennymi dotyczącymi udarów mózgu. Wykorzystując tą sieć mogliśmy np. obliczyć prawdopodobieństwo udaru dla osób, które mają nadciśnienie i są osobami starszymi.